20261030 指标修复说明

修复前 = `main`，修复后 = `fix-20261030`

2026 年 11 月

先说几句

- 每个指标两页：第一页讲它是什么、基准（HXZ 2020、GHZ 2017、JKP 2023、Chen–Zimmermann）怎么做、我们原来哪里不对；第二页讲改了什么，再放一张修复前后的对比表。
- 表里的列名就是最终文件 `chars_raw_no_impute.parquet` 里的列名。`date` 是最终文件里的 `date`，也就是收益所在的月份，指标在它上个月末算好。
- 红字是修复后变了的值，“空”是缺失。只有 `sgrvol` 一组用的是季度中间文件 `chars_q_accounting.parquet`，因为最终文件里没有它。
- 例子来自 2015–2021 年的样本（2012–2014 年作历史），1972 年以前的例子来自 1968–1975 年的样本。两边用的是同一份原始数据。

sue：标准化未预期盈利

- **指标**　最近一个季度的每股收益相对去年同季的变化，除以过去 8 个季度这种变化的标准差。
- **基准做法**　HXZ A.1.1。1972 年起，季度盈利要等公告日 `rdq` 过了才能用；1972 年以前没有 `rdq`，季末后 4 个月才能用。季末离当前超过 6 个月的季度不再用。过去 8 个季度的变化至少要有 6 个。
- **我们的问题**　原来只看季末 `datadate` 过没过，季度还没公告就拿来用了：2015–2021 年差不多一半的月份用到了尚未公告的季度。过期窗口是 12 个月。历史 EPS 是“往前数 k 行”，中间缺一个季度就整体错位。

sue：修正与前后对比

修正　改成 `rdq` 不晚于月末才能用（1972 年前用季末 + 4 个月），窗口改为 6 个月；历史 EPS 按同一 gvkey、往前正好 $3k$ 个月的季度去找。

permno 10028，2018Q4 到 2019-04-12 才公告。修1972 年以前，permno 44396。修复前季度结束当月 1972 年复前 1 月起就在用它。

date	sue（前）	sue（后）
2019-03-31	−0.158	−0.559
2019-04-30	−0.158	−0.559
2019-05-31	0.000	−0.158
2019-06-30	0.000	0.000

就用了。

月份	sue（前）	sue（后）
1970-12	5.752	0.604
1971-01	5.752	2.831
1971-04	−0.347	5.752

前的样本只跑到 `sue.parquet`，按形成月份列出。

abr：盈余公告前后的累计超额收益

- **指标**　公告日前 2 个交易日到后 1 个交易日，个股日收益减市场日收益的累计。
- **基准做法**　HXZ A.1.2。公告日必须晚于季末；季末离当前不超过 6 个月。
- **我们的问题**　不检查 `rdq` 是否晚于季末。过期窗口 12 个月，过期的 abr 一直挂着（约 4% 的月份）。同一天公告好几个季度时，日收益被加了好几遍（161 个公告）。先删掉缺失收益再数交易日，窗口会滑到别的日子（347 个值）。

abr：修正与前后对比

修正　要求 `rdq` 晚于 `datadate`；窗口改为 6 个月；每个（permno，公告日）只留一个事件；先数交易日再求和。市场收益仍用 `mktrf + rf`。

permno 92805，季末 2015-03-31，拖到 2015-08-11 才公告，之后 Compustat 里再没有新季度。修复前这个 abr 一直用到 2016 年 4 月。

date	abr（前）	abr（后）
2015-10-31	0.0187	0.0187
2015-11-30	0.0187	空
2016-01-31	0.0187	空
2016-04-30	0.0187	空

re：分析师盈利预测修正

- **指标**　过去 6 个月当年财年（FY1）一致预测的月度变化，除以上月股价，再加总。
- **基准做法**　HXZ A.1.3 (式 A2)。只用 FY1；月度修正 $= (f_t - f_{t-1})/p_{t-1}$；对最近 6 个月的修正求和，至少要有 4 个。财年结束到实际值公布之间，FY1 仍然是刚结束的那个财年。
- **我们的问题**　FY2 混进来了。`unique()` 打乱顺序后再 `shift`，滞后错位。用的是 $t-6$ 到 $t-1$，晚了一个月，而且取的是平均不是求和。下载条件 `fpedats >= statpers` 把财年结束后的 FY1 全删了。CRSP 累计调整因子为 0 时除法直接报错。

re：修正与前后对比

修正　只保留 FPI $= 1$。月度修正要求上一条预测正好是上个月。滞后按日历月取，和当月合起来有 4 个以上就求和。下载去掉 `fpedats >= statpers`，re 的覆盖多了 84%。调整因子为 0 当作缺失。

IBM（permno 12490），FY2017，单位 10^{-4}。IBM 1 月换财年，1 月没有修正；修复前 4、5 月拿到的其实是 FY2018 的预测。

date	re（前）	re（后）
2017-04-30	-1.82	0.54
2017-05-31	0.54	-3.60
2017-06-30	-1.90	-4.25
2017-07-31	-2.49	-4.25

财务滞后：agr 以及所有要用上期值的指标

- **指标** agr 是总资产同比增长。同样的滞后用在 ni、chcsho、cinvest、roavol、ttm4 等大约 100 处。
- **基准做法** JKP。上期值要来自同一家公司（gvkey），并且正好早 k 期：年度差 12 个月，季度差 3 个月。
- **我们的问题** `shift(k).over('permno')` 是往前数行。permno 换了 gvkey，就拿到前一家公司的数；中间缺一期，就拿到更早的那期。

财务滞后：修正与前后对比

修正 functions.py 加了 lag(列，k，months)：同 permno、同 gvkey、日期正好差 k 期（容差不到一期，财年月份变更也能对上）。99.7% 的值没变，约 1% 置空。1968–1975 年的季度覆盖反而多了，因为 main 把年度和季度混排后行距本来就不对。

permno 10253，2013 年 7 月 gvkey 从 012200 换成 018290。新公司一年前没有资产数据，修复前的 agr 拿的是老公司 2012 年的总资产。

date	gvkey	agr（前）	agr（后）
2014-05-31	018290	3.914	空
2014-06-30	018290	3.914	空
2014-07-31	018290	3.914	空

ni：股本净发行

- **指标**　拆股调整后股数的对数同比变化。
- **基准做法**　HXZ A.3.10。$\log(\text{csho} \times \text{ajex}) - \log(\text{一年前同值})$；任何一期股数缺失或非正，就缺失。
- **我们的问题**　缺失时 `fill_null(0)`，结果变成 $\log(\text{股数}) - 0$，也就是股数本身的对数。季度 7.5%、年度 6.9% 的 ni 是这种值。

ni：修正与前后对比

修正　两期股数都为正才算，否则为空。

permno 18100（gvkey 034077），2019Q1 的一年前（2018Q1）没有 cshoq。修复前的 3.446 就是 $\log(31.369)$。

date	ni（前）	ni（后）
2019-08-31	3.446	空
2019-09-30	3.446	空
2019-10-31	3.446	空

roa：季度总资产收益率

- **指标**　季度净利润 ibq 除以上季度总资产 atq。
- **基准做法**　HXZ A.4.3。用最近一次公告（rdq）的季度盈利，公告日必须晚于季末，季末要在 6 个月以内。其他非盈利类的季度项目仍用季末 + 4 个月。
- **我们的问题**　有一段“尽量用最新 ibq”的代码，把 ibq 换成下一季度的值，分母 atq_l1 却还是本季度的上一季，分子分母差了一个季度。

roa：修正与前后对比

修正　删掉那段替换。roa 先按季度算 $\text{ibq}_q/\text{atq}_{q-1}$，输出时按每个月最近一次公告取值，季末超过 6 个月不再用（没有 rdq 时退回季末 + 4 个月）。

permno 10026，2018 年。Q2 于 7 月 30 日公告，Q3 于 11 月 8 日公告。修复前 8 月那行分子是 Q2 的 ibq (26.129)，分母却是上一年 Q4 的 atq（865.017），而不是 Q1 的 887.549。

date	roa（前）	roa（后）	修复后用的季度
2018-08-31	0.0302	0.0294	2018Q2（7 月 30 日公告）
2018-11-30	0.0294	0.0294	2018Q2
2018-12-31	0.0294	0.0256	2018Q3（11 月 8 日公告）

cinvest：企业投资变化

- **指标**　本季度 ppentq/saleq 的变化，相对前 3 个季度同样变化的平均值。
- **基准做法**　GHZ。要有本季度和前 4 个季度的数据，不够就置空。
- **我们的问题**　前几期缺失也照算，平均数只用有的那几期。

cinvest：修正与前后对比

修正 `ppentq_l1` 到 `l4` 都有值才算（`lag()` 取同一家公司）。4.3% 的值置空。

permno 14423（gvkey 027046），2016Q1 才开始有 ppentq。2016Q4 那期（2017 年 5–7 月在用）前面只有 3 个季度。

date	cinvest（前）	cinvest（后）
2017-05-31	1.5	空
2017-06-30	1.5	空
2017-08-31	0.4	0.4

sgrvol、roavol：销售增长与盈利的波动

- **指标**　sgrvol 是过去 15 个季度 `rsup`（季度销售同比增量 / 季末市值）的标准差，roavol 是过去 16 个季度 roa 的标准差。两者进入 pscore（Mohanram 的 m7、m8）；最终文件里有 roavol 和 pscore，没有 sgrvol。
- **基准做法**　GHZ。在季度财报面板上算，sgrvol 用 t 到 $t-14$ 季，roavol 用 t 到 $t-15$ 季；rsup 的分母是季末市值；公司季度记录不到 17 个就置空。
- **我们的问题**　sgrvol 在月度面板上往前取 16 行，实际只覆盖 5 个季度左右，同一季度重复 3 次，分母还是每月变动的市值，所以同一季度里每个月的值都不一样。两者都没有 17 个季度的要求。

sgrvol、roavol：修正与前后对比

修正 和 roavol 一起在季度面板上算，rsup 用 main 已经下载的季末市值 `mveq_f`（`prccq`×`cshoq`），季度按 `lag()` 取同一家公司；不到 17 个季度置空。月度的 rsup 指标本身不变。roavol 也跟着变，因为它用的 roa 不再是被换过的 ibq。

permno 10026，取自 `chars_q_accounting.parquet`。修复前同一季度（2018-09-30）三个月给出三个不同的 sgrvol。

jdate	datadate	sgrvol（前）	sgrvol（后）	roavol（前）	roavol（后）
2019-01-31	2018-09-30	0.0076	0.0067	0.0080	0.0074
2019-02-28	2018-09-30	0.0085	0.0067	0.0080	0.0074
2019-03-31	2018-09-30	0.0092	0.0067	0.0080	0.0074
2019-04-30	2018-12-31	0.0093	0.0066	0.0079	0.0072

age：上市年数

- **指标**　公司在 Compustat 年度数据里出现了几年。
- **基准做法**　GHZ。按 gvkey 数 Compustat 的年度记录，逐年加 1。
- **我们的问题**　`cum_count` 在去重和排序之前就算了，年龄会跳、会倒退（样本里 13,695 次倒退）。

age：修正与前后对比

修正　从年度 Compustat 里取 gvkey 的 `datadate`，按日期排名（`rank('dense')`），仍写进 main 原有的 `count` 列。

permno 11581（gvkey 001706），每年 1 月那一行。

date	2013-01	2014-01	2015-01	2016-01	2017-01	2018-01	2019-01	2020-01	2021-01
age（前）	3	8	4	1	7	6	10	5	9
age（后）	1	2	3	4	5	6	7	8	9

年度、季度合并与下月收益 ret

- **指标**　把年度和季度指标合到每个股票月份，再配上下个月的收益 `ret` 作为预测目标。
- **基准做法**　JKP 按股票月份合并，公司变更时用最新的财报。CZ：年报在可用后（季末 + 4 个月）最多用 12 个月，也就是季末后 15 个月。JKP：财务数据最多用到季末后 12 个月，季报一样。下月收益必须是下一个日历月。
- **我们的问题**　按 gvkey 连接：还没有年报（年度 gvkey 为空）或者换了公司时，整行季度指标都丢了（2.9% 的行）。年报、季报都不设期限，停牌几年后复牌还在用旧财报。下月收益取的是“下一行”，停牌之后拿到的是几年后的收益（98 行）。

合并与下月收益：修正与前后对比（一）

修正　按（permno，月份）连接，季度那边的 gvkey 暂存为 `q_gvkey`；两边公司不同时保留财报较新的一边。年报超过季末 15 个月、季报超过季末 12 个月置空（季报只影响 0.07% 的行，都在停牌或缺报之后）。`ret` 只取下一个日历月。

permno 11990（gvkey 179741），2019 年 5 月才有第一份年报。修复前年度 gvkey 为空，季度算出来的 sue 整行丢掉。

date	gvkey（前 → 后）	sue（前）	sue（后）
2018-09-30	空 → 179741	空	0.628
2018-12-31	空 → 179741	空	1.397
2019-04-30	空 → 179741	空	−1.855

合并与下月收益：修正与前后对比（二）

permno 10051：2016 年 1 月后停牌，2018 年 9 月复牌。修复前 date 为 2018-09-30 的那一行，其实是 2016 年 1 月的指标配上了 2018 年 9 月的收益；复牌后还在用 2014 年的年报。

date	ret（前）	ret（后）	currat（前）	currat（后）
2018-09-30	−0.119	整行删除	1.875	整行删除
2018-10-31	−0.104	−0.104	1.875	空
2018-11-30	0.073	0.073	1.875	空

permno 11379：2020 年 11 月后停牌，2021 年 9 月复牌，最近的季报还是 2020-07-31，已经过了 14 个月。

date	agr（前）	agr（后）	cinvest（前）	cinvest（后）
2021-10-31	−0.187	空	0.064	空
2021-11-30	−0.187	空	0.064	空

其他小修

指标	原来的问题	修复后（依据）
dy（ttm12）	往前数 12 行，停牌时跨越超过 12 个月	要求连续 12 个日历月（JKP）
dy 的月度股息	用上一行的价格换算，会跨过缺失的月份	上一行必须是上个月（JKP）
季度财报去重	财年变更时同一个 datadate 有两行（全库 1,580 对），unique() 随机留一行，重跑结果不一样	每个(gvkey,datadate)按 fyearq，fqtr 排序留最后一行（JKP）；sue、abr、财务指标三处一致

数据下载 download_data.py

- 只登录 WRDS 一次，DuckDB 限制为 1 个连接（默认最多 64 个并行连接，每个都是一次登录和 Duo 推送）。登录失败立即退出，不重试。
- 增量更新：本地已有的表只下载最近一段（Compustat、IBES 从最新日期往前 24 个月，CRSP 3 个月），替换本地同期的行。ccm 很小，每次全量。新表或 --full 才全量下载。
- 某张表失败时脚本停下来，不再重新连接；已经完成的表已保存，下次只补剩下的。
- IBES 的下载条件去掉 fpedats >= statpers（见 re 那一组），IBES 也按 statpers 增量更新。
- iclink_ciz.csv（IBES–CRSP 链接）仍由 iclink_ciz.sas 生成，不经过这个脚本。
- 用法：python download_data.py 全部更新；--tables ibes crsp_msf 只更新这几张；--full ibes 这张表重新全量下载。

没有采纳的，和还没处理的

没有采纳（原分支提过，但基准不要求，或影响很小）	
年度数据改为次年 6 月形成	这是 HXZ 年度组合的做法；我们的面板按月更新，沿用季末 + 4 个月（JKP）。改了会动约 28% 的年度值。
abr 改用 `vwretd`	和 `mktrf + rf` 相关 0.998，abr 的截面排序几乎不变。
re 改用 IBES 未调整预测和 IBES 价格	和现做法截面秩相关 0.986；要新增一张表和拆股换算。
abr 要求四天收益齐全、按月核对 CCM 链接	HXZ 没有这个要求；只有 JKP 按月核对链接。
还没处理	
gvkey 当月的 CCM 链接已经失效	约 0.6% 的股票月份，JKP 级别的要求。

附：文献原文

后面几页是基准做法的原文截图，按前面的顺序：HXZ 的时点规则、sue、abr、re、ni、roa，以及 GHZ 的 cinvest。

HXZ：时点规则

For annually sorted deciles, we split stocks at the end of June of each year t into deciles on a variable measured at the fiscal year ending in calendar year $t-1$ and calculate decile returns from July of year t to June of $t+1$. For monthly sorted portfolios involving the latest earnings data, we use quarterly earnings data in the months immediately after quarterly earnings announcement dates (Compustat quarterly item RDQ). For monthly sorted portfolios involving quarterly accounting data other than earnings, we impose a 4-month lag between the fiscal quarter end and subsequent returns. Unlike earnings, other quarterly

HXZ A.1.1: sue

A.1.1 Sue1, Sue6, and Sue12, standardized unexpected earnings. Per Foster, Olsen, and Shevlin (1984), Sue denotes Standardized Unexpected Earnings, and is calculated as the change in split-adjusted quarterly earnings per share (Compustat quarterly item EPSPXQ divided by item AJEXQ) from its value four quarters ago divided by the standard deviation of this change in quarterly earnings over the prior eight quarters (six quarters minimum). At the beginning of each month t, we split all NYSE, Amex, and NASDAQ stocks into deciles based on their most recent past Sue. Before 1972, we use the most recent Sue computed with quarterly earnings from fiscal quarters ending at least four months prior to the portfolio formation. Starting from 1972, we use Sue computed with quarterly earnings from the most recent quarterly earnings announcement dates (Compustat quarterly item RDQ). For a firm to enter our portfolio formation, we require the end of the fiscal quarter that corresponds to its most recent Sue to be within six months prior to the portfolio formation. We do so to exclude stale information on earnings. To avoid potentially erroneous records, we also require the earnings announcement date to be after the corresponding fiscal quarter end. Monthly portfolio returns are calculated, separately, for the current month t

A.1.2 Abr1, Abr6, and Abr12, cumulative abnormal returns around earnings announcement dates. We calculate cumulative abnormal stock return (Abr) around the latest quarterly earnings announcement date (Compustat quarterly item RDQ) (Chan, Jegadeesh, and Lakonishok 1996):

$$\text{Abr}_i = \sum_{d=-2}^{+1} r_{id} - r_{md}, \tag{A1}$$

in which r_{id} is stock i's return on day d (with the earnings announced on day 0) and r_{md} is the value-weighted market index return. We cumulate returns until one (trading) day after the announcement date to account for the 1-day-delayed reaction to earnings news.

A.1.3 Re1, Re6, and Re12, revisions in analyst earnings forecasts. Following Chan, Jegadeesh, and Lakonishok (1996), we measure earnings surprise as the revisions in analysts' forecasts of earnings obtained from the Institutional Brokers' Estimate System (IBES). Because analysts' forecasts are not necessarily revised each month, we construct a 6-month moving average of past changes in analysts' forecasts:

$$\text{Re}_{it} = \sum_{\tau=1}^{6} \frac{f_{it-\tau} - f_{it-\tau-1}}{p_{it-\tau-1}}, \tag{A2}$$

in which $f_{it-\tau}$ is the consensus mean forecast (unadjusted IBES file, item MEANEST) issued in month $t-\tau$ for firm i's current fiscal year earnings (fiscal period indicator = 1), and $p_{it-\tau-1}$ is the prior month's share price (unadjusted file, item PRICE). We require both earnings forecasts and share prices to be in U.S. dollars (currency code = USD). We also adjust for any stock splits and require a minimum of four monthly forecast changes when constructing Re. At the beginning

HXZ A.3.10：ni

A.3.10 Nsi, net stock issues. At the end of June of year t, we measure net stock issues, Nsi, as the natural log of the ratio of the split-adjusted shares outstanding at the fiscal year ending in calendar year $t-1$ to the split-adjusted shares outstanding at the fiscal year ending in $t-2$. The split-adjusted shares outstanding is shares outstanding (Compustat annual item CSHO) times the adjustment factor (item AJEX). At the end of June of each year t, we sort stocks with negative Nsi

HXZ A.4.3: roa

A.4.3 Roa1, Roa6, and Roa12, return on assets. Return on assets, Roa, is income before extraordinary items (Compustat quarterly item IBQ) divided by 1-quarter-lagged total assets (item ATQ). At the beginning of each month t, we sort stocks into deciles on Roa computed with quarterly earnings from the most recent earnings announcement dates (item RDQ). For a firm to enter the portfolio formation, we require the end of the fiscal quarter that corresponds to its most recent Roa to be within six months prior to the portfolio formation. We also require the earnings announcement date to be after the corresponding fiscal quarter end. Monthly decile returns are calculated for

GHZ：cinvest

cinvest	Titman, Wei & Xie	2004, JFQA	Change over one quarter in net PP&E (*ppentq*) divided by sales (*saleq*) - average of this variable for prior 3 quarters; if *saleq* = 0, then scale by 0.01.